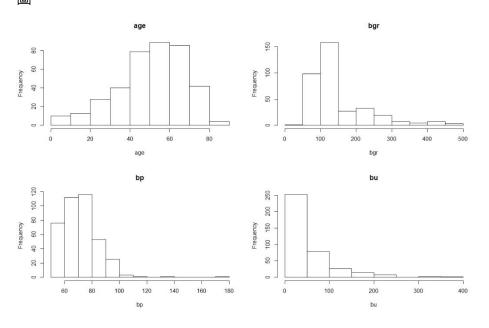
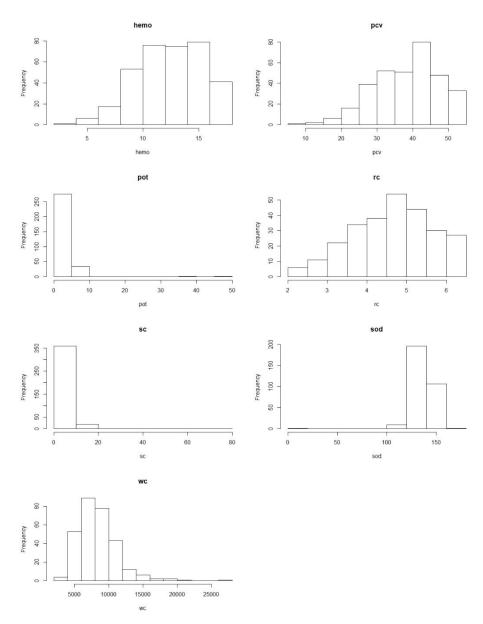
- Data Preprocessing and Generalized Linear Model (GLM)/Logistic Regression
 - (1) Provide the descriptive statistics. Eg. mean, variance, data distribution, # of missing value, # of outlier, etc.

先利用資料給的說明敘述,區分出類別變數及非類別變數,之後透過 Summary 函式得到基本的敘述統計,輸出結果如圖。

另外,針對數值型的資料畫出 data distribution,以下為 age、bgr、bp、bu、hemo、pcv、pot、rc、sc、sod、wc 的頻率分布圖。





再來,將數值型資料的 variance 算出,以下為輸出結果。

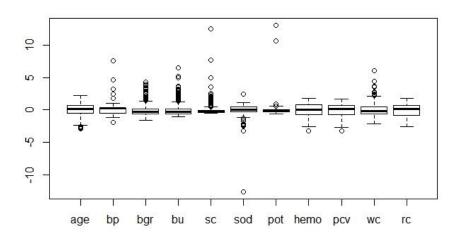
```
> var(Kidney_data$age,na.rm=TRUE)
[1] 294.7991
> var(Kidney_data$bp,na.rm=TRUE)
[1] 187.2419
> var(Kidney_data$bgr,na.rm=TRUE)
[1] 6285.59
> var(Kidney_data$bu,na.rm=TRUE)
[1] 2550.554
> var(Kidney_data$bu,na.rm=TRUE)
[1] 32.96053
> var(Kidney_data$sod,na.rm=TRUE)
[1] 108.3421
> var(Kidney_data$rc,na.rm=TRUE)
[1] 109341

> var(Kidney_data$rc,na.rm=TRUE)
[1] 1.019341
```

(2) Remove the observation without "class" value

透過計算可以得知總共有 13 筆資料沒有 class 的值,因此利用 complete.cases()函式將資料移除。

(3) How to identify the outlier? How to impute the missing value? 可以透過標準化分數或是盒鬚圖來判斷離群值。標準化分數部分,透過將資料轉為標準化分數,當資料落於 Z 分數正負 3 (亦可自訂其他分數數值)之外,就判定其為離群值。盒鬚圖部分,則是畫出盒鬚圖取出 Q1、Q3,當資料落於 3 倍 IQR 的距離之外,即可判定為離群值。以下為標準化過後的盒鬚圖。



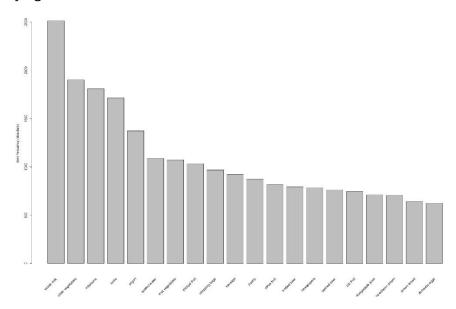
填補遺失值部分可以透過平均值、第一四分位數、KNN 或 MICE 方法來填補,此次我是使用 KNN 來填補,具體作法如附檔程式碼。

- (4) How to transform the categorical variable to dummy variable? 在 R 裡面可以透過 dummies 套件轉換,具體作法如附檔程式碼。
- (5) How to "randomly" split the dataset into training dataset and testing dataset (eg. 80% vs. 20%)? 隨機切割資料可以透過 sample 函式指定資料範圍與大小之後產出 index,再利用 index 去分割 training 與 test 資料集。
- (6) Please use the Generalized Linear Model (GLM)/Logistic Regression to predict the "Class" in the testing dataset. 透過 glm(formula, family, data)函式來實作 Logistic 迴歸並預測,具體作法如附檔程式碼。最後預測的準確結果與否如圖。

2. Association Rule Market Basket Analysis

(1) How to handle the raw dataset via data preprocessing?

透過 read.transaction 將資料讀進 R·並且看看最常被買的產品有哪些·並且針對各產品的頻率畫出長條圖·可以看出最常被購買的產品前五名分別是 whole milk、other vegetables、rolls/buns、soda、yogurt。



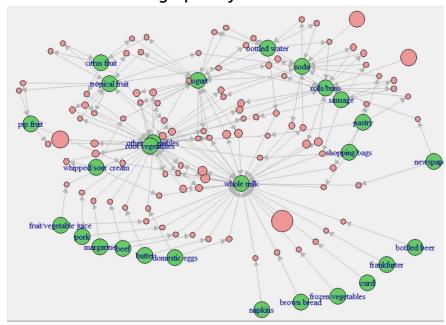
(2) What's the top 5 association rules? Show the support, confidence, and lift to each specific rule, respectively?

前五名的關聯規則分別是{bottled beer, red/blush wine}配{liquor}、 {hamburger meat, soda}配{Instant food products}、 {ham, white bread}配{processed cheese}、 {other vegetables, root vegetables, whole milk, yogurt}配{rice}以及{bottled beer, liquor}配{red/blush wine}。各自的 support, confidence, lift 如下圖。

(3) Please provide/guess the "story" to interpret one of top 5 rules you are interested in.

我比較感興趣的是第三名關聯規則{ham, white bread}配{processed cheese},這個關聯應該是有消費者想要自己動手做漢堡。因為漢堡的組成最基本的就是白麵包、火腿以及起司,所以消費者一起買這些東西還彎合理的。

(4) Give a visualization graph of your association rules.



Scatter plot for 50 rules

